

サーフィン事故と海の安全 ダッシュボード

米国のサーフィン事故データを集計・分析し、重症度に影響する要因を探るデータ分析プロジェクト。リポジトリ: github.com/ocan170712-spec/surf-safety-dashboard

Streamlitで作った操作可能なダッシュボードで、傾向の可視化・統計検定・機械学習による重症度予測を確認できる。

データソース

データセット	内容	範囲	出典
NEISS	米国の救急外来(ER)におけるサーフィン受傷記録	2010～2025年, 1,850件	CPSC National Electronic Injury Surveillance System
Global Shark Attack File	シャーク被害の記録(米国分に絞り込み、うちサーフィン関連695件)	1900年代～2016年ごろ	sharkattackfile.net のミラー(GitHub)

留意点(データの限界)

- 両データとも米国のみが対象で、世界全体はカバーしていません。
- Global Shark Attack Fileは2016年ごろまでのスナップショットで、近年のデータは含まれません。
- シャーク被害の位置情報は州名のみで緯度経度がいないため、マップ上の点は各州の中心付近にランダムに散らした近似表示です。正確な発生地点ではありません。
- NEISSは全数調査ではなく、米国内の一部病院からの重み付きサンプル調査です(Weight列に国全体推計用の重みが入っています)。


主な発見

NEISSデータ(1,850件)を分析した結果、以下の傾向が見られた(詳細分析タブのロジスティック回帰・オッズ比による)。



- 年齢の影響が最も一貫して強い: 1歳上がるごとに重症化オッズが約3.5%上昇(オッズ比1.04, $p<0.001$)。特に60歳以上は重症化率が11～27%と若年層(多くが5%未満)の数倍に達する。
- 年齢と季節の組み合わせが顕著:
60歳以上に限ると、夏の重症化率は27%、春は20%と、秋・冬(約11%)の2倍以上。
- 受傷部位が重症度を大きく左右: 体幹(Trunk)の負傷は腕・手に比べて重症化オッズが約6.4倍($p<0.001$)、頭部・顔・首は約3.4倍($p<0.01$)。
- 性別による差: 男性は女性よりも重症化オッズが約2.0倍($p=0.02$)。
- 季節単体では有意差なし:
季節と重症度のカイ二乗検定は $p=0.579$ で、明確な関連は確認できなかった。
- 重症度予測モデルの限界: ランダムフォレストによる3クラス分類は全体精度76%だが、中等症(21件)は事実上判別不能、重症の適合率も0.18と低め。

分析結果(グラフ・詳細データ)


年別の受傷件数推移



重症度の内訳と年齢×季節の重症化率




重症化に関わる要因(オッズ比)



要因	オッズ比	信頼区間下限	信頼区間上限	p値
body_part_group = Other	13.196	1.097	158.699	0.042
body_part_group = Trunk	6.427	2.903	14.228	0.0
body_part_group = Head/Face/Neck	3.368	1.572	7.214	0.002
body_part_group = Leg/Foot	2.311	1.003	5.322	0.049
sex = Male	1.959	1.124	3.413	0.018
season = Summer	1.432	0.881	2.328	0.148
season = Winter	1.124	0.593	2.129	0.72
age (+1 year)	1.035	1.024	1.047	0.0
season = Spring	0.859	0.454	1.626	0.641

予測モデル(ランダムフォレスト)の評価



	適合率	再現率	F1スコア	件数
軽症	0.96	0.78	0.86	429.0
中等症	0.0	0.0	0.0	5.0
重症	0.18	0.59	0.27	29.0
全体精度	0.76	0.76	0.76	0.76
マクロ平均	0.38	0.46	0.38	463.0
加重平均	0.9	0.76	0.82	463.0

手法

- 1 クリーニング: 表記ゆれを統一し、季節・年齢層・重症度などの特徴量を作成(clean_neiss.py, clean_shark_attacks.py)。
- 2 記述統計・検定:
部位・年齢層・季節別の重症度分布を集計し、カイ二乗検定で季節と重症度の関連を検証。
- 3 説明モデル(ロジスティック回帰):
診断結果を使わず、事故発生時点でわかる要因だけで重症化オッズを説明(stats.py)。
- 4 予測モデル(ランダムフォレスト): 診断分類も使い、重症度を予測(model.py)。

説明モデルと予測モデルで使う特徴量をあえて分けているのは、診断分類を含めると「骨折だから重症」という自明な結果になりがちなため。

ダッシュボードの構成

- 概要: 全体件数・重症割合などのKPI、年別推移、重症度と季節の内訳。サイドバーの年スライダーで対象期間を絞り込み可能。
- 詳細分析: 部位・年齢層別の重症度、季節×重症度の検定、年齢×季節の重症化率ヒートマップ、オッズ比のフォレストプロット、サメ被害の州別マップ。
- 予測モデル: 年齢・性別・季節・部位・診断分類を入力すると重症度の予測確率を表示。

ディレクトリ構成

```
data/raw, data/processed
src/clean_neiss.py, clean_shark_attacks.py, stats.py, model.py
app/app.py, geo.py
```

セットアップと実行方法

```
pip install -r requirements.txt
python src/clean_neiss.py
python src/clean_shark_attacks.py
python src/model.py
streamlit run app/app.py
```

今後の展望

- 世界規模のデータ(国別の波情報・ブレイクの種類など)を追加できれば、グローバルなマップ分析に拡張可能。
- 重症クラスのサンプルが少ないため、SMOTE等でクラス不均衡に対応するとモデル精度の改善が見込める。